RT-2：视觉-语言-行动模型将网络知识传递到机器人控制

安东尼・布罗汉、诺亚・布朗、贾斯蒂斯・卡巴哈尔、叶夫根・切博塔尔、习 陈、克日什托夫・乔罗曼斯基、丁天立、丹尼・德里斯、阿维纳瓦・杜贝、切尔西・芬恩、皮特・弗洛伦斯、傅楚媛、蒙特塞・冈萨雷斯・阿雷纳斯、基尔塔娜・戈帕拉克里希南、韩克恒、卡罗尔・豪斯曼、亚历山大・赫尔佐格、许嘉敏、布莱恩・伊希特、亚历克斯・伊尔潘、尼基尔・乔希、瑞安・朱利安、德米特里・卡拉什尼科夫、光玉衡、伊莎贝尔・利尔、李丽莎、曾伟、李爱德华， 谢尔盖・莱文、姚璐、亨里克・米哈莱夫斯基、伊戈尔・莫尔达奇、卡尔・佩尔奇、卡尼什卡・拉奥、克里斯塔・雷曼、迈克尔・梁、格雷西亚・萨拉查、潘纳格・桑凯蒂、皮埃尔・塞尔马内、贾斯皮亚尔・辛格、阿尼凯特・辛格、拉杜・索里库特、陈洪、文森特・范霍克、权武、艾赞・瓦希德、斯特凡・韦尔克、保罗・沃尔哈特、吴嘉林、菲・夏、泰德・萧、彭・徐、徐思春、于天和和布里安娜・齐特科维奇 Google DeepMind。作者按字母顺序列出，贡献列于附录 A。

arXiv：2307.15818v1 [cs.RO] 2023 年 7 月 28 日

我们研究如何将基于互联网规模数据训练的视觉语言模型直接整合到端到端的机器人控制中，以增强泛化能力并实现涌现语义推理。我们的目标是实现单一端到端训练模型，既能学习将机器人观察映射到动作，也能享受网络语言和视觉语言数据大规模预训练的好处。为此，我们计划对机器人轨迹数据和互联网规模视觉语言任务（如视觉问答）进行协同微调。与其他方法不同，我们提出了一个简单通用的方案来实现这一目标：为了将自然语言响应和机器人动作都融入同一格式，我们将动作表达为文本符号，并以自然语言符号的方式直接将其纳入模型的训练集。我们将此类模型称为视觉-语言-行动模型（VLA），并实例化一个此类模型的例子，称为 RT-2。我们广泛的评估（6k 评估试验）表明，我们的方法能够实现高效的机器人策略，并使 RT-2 能够从互联网规模训练中获得一系列涌现能力。这包括对新对象的显著推广，能够解释机器人训练数据中未存在的命令（如将物体放置在特定数字或图标上），以及对用户指令进行基础推理的能力（如拾取最小或最大物体，或靠近另一个物体的物体）。 我们还进一步证明，结合思维链推理使 RT-2 能够执行多阶段语义推理，例如判断应拾起哪种物品作为临时锤子（石头），或选择哪种饮品最适合疲劳者（能量饮料）。

1. 引言

在广泛网络规模数据集上预训练的高容量模型为广泛的下游任务提供了有效且强大的平台：大型语言模型不仅能实现流利文本生成（Anil 等，2023;Brohan 等，2022;OpenAI，2023）但同时也涉及涌现性问题解决（Cobbe 等，2021;Lewkowycz 等，2022;Polu 等，2022）以及散文的创造性生成（Brown 等，2020;OpenAI，2023）和代码（Chen 等，2021），而视觉语言模型则实现了开放词汇的视觉识别（Kirillov 等，2023;Minderer 等，2022;Radford 等，2021），甚至能对图像中对象-代理的相互作用做出复杂推断（Alayrac 等，2022;Chen 等，2023a，b;Driess 等，2023;Hao 等，2022;Huang 等，2023;Wang 等，2022）。这种语义推理、问题解决和视觉解释能力对于需要在现实环境中执行多种任务的通用机器人来说将非常有用。然而，

通讯作者：chebotar@google.com，tianheyu@google.com，karolhausman@google.com © 2023 Google DeepMind。保留所有权利

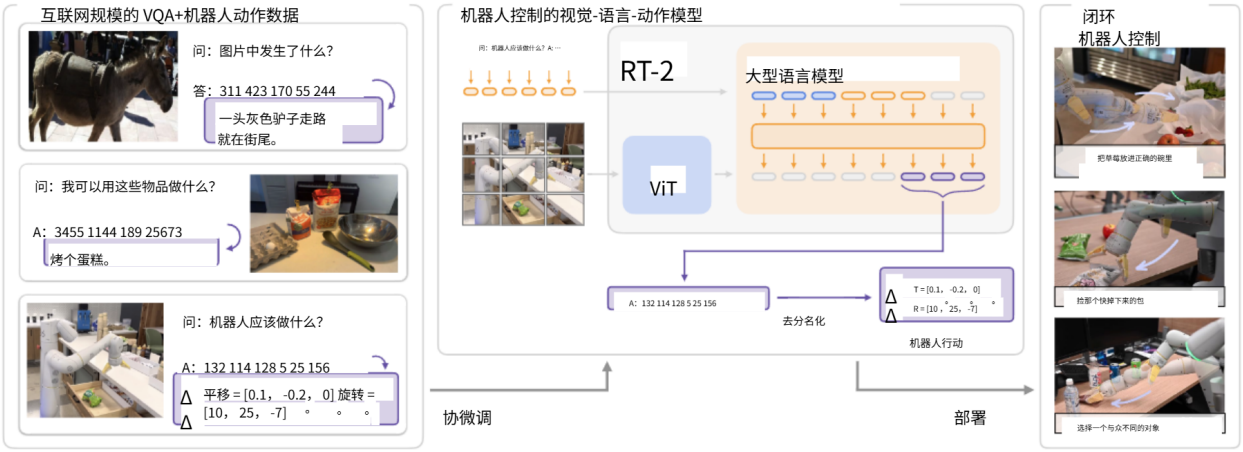

图 1 |RT-2 概述：我们将机器人动作表示为另一种语言，可以转换为文本标记，并与互联网规模的视觉语言数据集共同训练。在推理过程中，文本标记被去标记化为机器人动作，实现闭环控制。这使我们能够利用视觉语言模型的骨干和预训练来学习机器人策略，将其部分泛化、语义理解和推理转移到机器人控制中。我们在项目网站上展示了 RT-2 的执行示例：robotics-transformer2.github.io。

目前尚不清楚机器人如何获得这些能力。暴力破解方法可能需要收集数百万次机器人交互试验，但最强大的语言和视觉语言模型是基于数十亿个网络上的令牌和图像训练的（Alayrac 等，2022;Chen 等，2023a，b;Huang 等，2023）——这一数字在近期内不太可能与机器人数据匹配。另一方面，直接将此类模型应用于机器人任务也较为困难：此类模型需要推理语义、标签和文本提示，而机器人则需要基于底层的操作，如笛卡尔末端执行器命令。虽然近期有许多研究试图将语言模型（LLMs）和视觉语言模型（VLMs）融入机器人技术（Ahn 等，2022;Driess 等，2023;Vemprala 等，2023），这类方法通常只涉及机器人规划的“高层次”方面，本质上扮演状态机的角色，解释命令并将其解析为单个原语（如选择和放置对象），然后由独立的低级控制器执行，这些控制器本身在训练过程中并未受益于互联网规模模型丰富的语义知识。因此，本文探讨：大型预训练视觉语言模型能否直接集成到低级别机器人控制中，以促进泛化并实现新兴语义推理？

为此，我们探索一种既简单又出人意料地有效的方法：我们直接训练设计用于开放词汇视觉问题回答和视觉对话的视觉语言模型，以输出低层次机器人动作，同时解决其他互联网规模的视觉语言任务。虽然这类模型通常训练用于生成自然语言词，但我们可以通过将动作分词为文本词符并创建“多模态句子” Driess 等，2023），这些句子通过生成相应动作来“响应”机器人指令与摄像头观察。通过这种方式，视觉语言模型可以直接训练，使其作为遵循机器人策略的指令。这种简单的方法与此前将 VLM 纳入机器人策略（Shridhar 等，2022a）或从零设计新的视觉语言动作架构（Reed 等，2022）形成对比：相反，已有的视觉语言模型，已摊销了大量计算资源，在不添加任何新参数的情况下训练以输出文本编码动作。我们将这类模型称为视觉-语言-行动（VLA）模型。我们基于 RT-1 提出的协议（Brohan 等，2022 年）实现了 VLA 模型，使用类似数据集，但扩展模型以使用大型视觉语言骨干。因此，我们将模型称为 RT-2（机器人变压器 2）。我们在图 1 中提供了概述。

我们观察到，基于此类视觉语言模型的机器人策略展现出一系列显著能力，将从机器人数据中学习的物理动作与从网络数据中学习到的图像和文本解读到单一模型的能力结合起来。除了显著提升对新对象和语义多样指令的泛化能力的预期好处外，我们还观察到若干涌现能力。虽然模型的身体技能仍局限于机器人数据中技能的分布，但模型通过利用从网络中获得的知识，解读图像和语言指令，获得了以新方式部署这些技能的能力。图 2 展示了一些示例高亮。该模型能够重新利用从机器人数据中学到的技能，将物体放置在语义指示位置附近，如特定数字或图标，尽管这些线索在机器人数据中并不存在。模型还可以解释物体之间的关系，以决定选择哪个物体以及放置在哪里，尽管机器人演示中未提供此类关系。此外，如果我们用思维链提示来增强命令，模型能够做出更复杂的语义推断，比如找出应拾取的物品作为临时锤子（石头），或哪种饮料最适合疲劳者（能量饮料）。

我们的主要贡献是 RT-2，这是一系列模型，源自对基于网络规模数据训练的大型视觉语言模型的微调，使其直接作为可泛化且语义感知的机器人策略。我们的实验研究了基于互联网数据和带有指令注释的机器人轨迹训练的多达 55B 参数的模型（Brohan 等，2022）。通过 6k 机器人评估，我们表明 RT-2 在对象、场景和指令的泛化能力上实现了显著提升，并展现了网络规模视觉语言预训练继承的广泛新兴能力。

2. 相关工作

视觉语言模型。视觉语言模型（VLMs）分为几类（Gan 等，2022），其中两个最为相关：（1）表征学习模型，例如 CLIP（Radford 等，2021），学习两种模态的共同嵌入；（2）视觉语言模型，形式为 {vision， text} → {text}，学习将视觉和语言作为输入，提供自由形式文本。这两类都被用于为多种下游应用提供预训练，如对象分类（Radford 等，2021）、检测（Gu 等，2021）和分割（Ghiasi 等，2021）。本研究重点关注后者（Alayrac 等，2022;Chen 等，2023a，b;Driess 等，2023;Hao 等，2022;Li 等，2023,2019;Lu 等，2019）。这些模型通常会同时训练多种任务，如图片标题、视觉问题解答（VQA）以及多个数据集上的通用语言任务。虽然以往研究已研究 VLM 在多种问题和场景中的应用，包括机器人领域，但我们的重点是如何通过赋予 VLM 预测机器人动作的能力，将其能力扩展到机器人闭环控制，从而利用 VLM 已有的知识，实现新的推广层次。

机器人学习中的推广。开发能够在多种场景下广泛成功的机器人控制器是机器人研究的长期目标（Kaelbling，2020;史密斯和科尔斯，1973 年）。实现机器人操作泛化的一个有前景方法是从大量且多样化的数据集中学习（Dasari 等，2019;Levine 等，2018;Pinto 和 Gupta，2016）。通过这种方法，先前的方法已经证明机器人可以推广到新对象实例（Finn 和 Levine，2017;Levine 等，2018;Mahler 等，2017;Pinto 和 Gupta，2016 年;Young 等，2021），以及涉及物品与技能新组合的任务（Dasari 和 Gupta，2021;Finn 等，2017;James 等，2018;Jang 等，2021;Yu 等，2018），到新的目标或语言指令（Jang 等，2021;Jiang 等，2022;Liu 等，2022;Mees 等，2022;Nair 等，2022a;Pong 等人，

2019 年），到具有新颖语义对象类别的任务（Shridhar 等，2021;Stone 等，2023），以及看不见的环境（Cui 等，2022;Du 等，2023a;Hansen 等，2020）。与以往大多数工作不同，我们旨在开发和研究一个能够沿所有这些轴的未知条件推广的单一模型。我们方法的关键要素是利用已接触到远比机器人所见数据更广泛的预训练模型。

机器人操作的预训练。预培训在机器人学习中有着悠久的历史。大多数研究聚焦于预训练的视觉表示，这些表示可用于初始化机器人摄像头观测的编码器，可以通过监督式 ImageNet 分类（Shah 和 Kumar，2021），数据增强（Kostrikov 等，2020;Laskin 等，2020a，b;Pari 等，2021）或针对机器人控制的目标（Karamcheti 等，2023;马等，2022;Majumdar 等，2023b;Nair 等，2022b;Xiao 等，2022b）。其他研究也采用了预训练语言模型，通常作为指令编码器（Brohan 等，2022;Hill 等，2020;Jang 等，2021;Jiang 等，2022;Lynch 和 Sermanet，2020 年;Nair 等，2022a;Shridhar 等，2022b）或用于高层次规划（Ahn 等，2022;Driess 等，2023;Huang 等，2022;Mu 等，2023;Singh 等，2023;Wu 等，2023）。我们不使用预训练视觉模型或预训练语言模型，而是专门考虑使用预训练视觉语言模型（VLM），它们提供了丰富且扎实的世界知识。此前的研究研究了 VLM 在机器人领域的应用（Driess 等，2023;Du 等，2023b;Gadre 等，2022;Karamcheti 等，2023;Shah 等，2023;Shridhar 等，2021;Stone 等，2023），并成为本研究灵感的一部分。 这些先前的方法使用 VLM 进行视觉状态表示（Karamcheti 等，2023），用于识别物体（Gadre 等，2022;Stone 等，2023），用于高层次规划（Driess 等，2023），或用于监督或成功检测（Du 等，2023b;马等，2023;Sumers 等，2023;Xiao 等，2022a;Zhang 等，2023）。虽然 CLIPort（Shridhar 等，2021）和 MOO（Stone 等，2023）将预训练的 VLM 整合进端到端的视觉运动操控策略中，但两者都包含了重要的结构，限制了其适用性。值得注意的是，我们的作品不依赖于受限的二维动作空间，也不需要经过校准的摄像机。此外，一个关键区别在于，与这些工作不同，我们利用生成语言的 VLM，而我们表述的统一输出空间使模型权重能够在语言和动作任务间完全共享，而无需引入仅操作的模型层组件。

3. 视觉-语言-行动模型

在本节中，我们将介绍我们的模型家族以及设计选择，以实现训练 VLM 直接执行闭环机器人控制。首先，我们描述模型的总体架构，以及如何从常用的视觉语言任务模型中推导出模型。随后，我们介绍了如何微调基于网络规模数据预训练的大型 VLM 的方案和挑战，这些 VLM 可直接输出机器人动作，成为 VLA 模型。最后，我们描述了如何使这些模型在机器人任务中实用，解决模型规模和推理速度带来的挑战，从而实现实时控制。

3.1. 预训练视觉语言模型

视觉语言模型（Chen 等，2023a;Driess 等，2023）在这项工作基础上，我们以一张或多张图像作为输入，生成一系列符号，通常代表自然语言文本。此类模型能够执行广泛的视觉解读和推理任务，从推断图像的组成到回答关于单个物体及其与其他物体关系的问题（Alayrac 等，2022;Chen 等，2023a;Driess 等，2023;Huang 等，2023）。代表完成如此广泛任务所需的知识

2023 年）需要大型模型和网络规模的数据集。本研究中，我们将两个此前提出的 VLM 改编为 VLA 模型：PaLI-X（Chen 等，2023a）和 PaLM-E（Driess 等，2023）。我们将这些模型的视觉-语言-动作版本称为 RT-2-PaLI-X 和 RT-2-PaLM-E。我们利用这些模型的实例化，参数大小从数十亿到数百亿不等。我们在附录 D 中详细描述了这两种模型的架构。

图 2 |RT-2 能够推广到各种需要推理、符号理解和人类识别的现实情境。我们在第四部分详细研究这些具有挑战性的情景。

3.2. 机器人动作微调

为了使视觉语言模型能够控制机器人，必须训练它们输出动作。我们直接处理该问题，将动作表示为模型输出中的令牌，这些令牌的处理方式与语言令牌相类。我们的动作编码基于 Brohan 等人（2022）提出的 RT-1 模型离散化。动作空间包括机器人端执行器的 6-DoF 位置和旋转位移，以及机器人夹持器的伸展水平和一个特殊的离散终止指令，该命令应由策略触发以表示成功完成。连续维度（除离散终止命令外的所有维度）被均匀地离散化为 256 个箱。因此，机器人动作可以用离散箱的序数表示为 8 个整数。为了利用这些离散化的动作将视觉语言微调为视觉语言动作模型，我们需要将模型现有分词中的标记与离散动作箱关联起来。这需要

保留 256 个代币作为行动代币。选择哪种标记取决于每个 VLM 所使用的具体分词方式，我们会在本节后面讨论。为了定义 VLM 微调的目标，我们将动作向量转换为单一字符串，方法是简单地将每个维度的动作标记与空格字符串接：

“终止ΔposΔposΔrotrotgripper_extensionΔrotΔ”。

该目标的可能实例化为：“1 128 91 241 5 101 127”。我们在实验中微调的两个 VLM 分别是 PaLI-X（Chen 等，2023a）和 PaLM-E（Driess 等，2023），使用了不同的分词方式。对于 PaLI-X，每个整数最多 1000 都有唯一的令牌，因此我们只需将动作箱关联到代表对应整数的令牌。对于 PaLM-E 模型，它不提供这种方便的数字表示，我们只需覆盖 256 个最少使用的标记来表示动作词汇。值得注意的是，训练 VLM 用动作标记覆盖现有标记是一种符号调优（Wei 等，2023），在先前研究中已被证明对 VLM 效果良好。

基于上述动作表示，我们将机器人数据转换为适合 VLM 模型微调的对象，输入包括机器人摄像头图像和文本任务描述。这需要（使用标准 VQA 格式）“问：机器人应对[任务指令]采取什么动作？A：”，我们的输出格式为一串数字/最少使用的标记，代表机器人动作。

协同微调。正如我们将在实验中展示的，提升机器人性能的训练配方中一个关键技术细节是将机器人数据与原始网络数据共同微调，而不仅仅是对机器人数据进行简单微调。我们注意到，协微调导致了更具通用性的策略，因为策略在微调过程中同时接触到来自网络规模数据的抽象视觉概念和低层机器人动作，而不仅仅是机器人动作。在协微调过程中，我们通过增加机器人数据集的采样权重，平衡每个训练批次中机器人和网页数据的比例。

输出约束。RT-2 与标准 VLM 的一个重要区别是，RT-2 必须输出有效的动作令牌以执行真实机器人。因此，为了确保 RT-2 在解码过程中输出有效的动作标记，我们通过仅在机器人动作任务提示时采样有效动作标记来限制其输出词汇，而模型在标准视觉语言任务中仍允许输出全部自然语言标记。

3.3. 实时推断

现代 VLM 的规模可达数百亿甚至数千亿参数（Chen 等，2023a;Driess 等，2023）。本研究中训练的最大模型使用 55B 参数。在标准的桌面式机器或用于实时机器人控制的机器人 GPU（机器人上）上直接运行此类模型是不可行的。据我们所知，我们的模型是有史以来最大的，超过一个数量级，用于直接闭环机器人控制，因此需要一套新的解来实现高效的实时推断。我们开发了一种协议，允许我们将 RT-2 模型部署在多 TPU 云服务中，并通过网络查询该服务，从而在机器人上运行。通过这一方案，我们可以实现合适的控制频率，同时也能为多个机器人提供相同的云服务。我们评估的最大模型是 55B 参数的 RT-2-PaLI-X-55B 模型，其频率可运行于 1-3 Hz。该模型的较小版本由 5B 参数组成，频率约为 5 赫兹。

4. 实验

我们的实验聚焦于 RT-2 的现实世界的泛化和新兴能力，旨在回答以下问题：

1. RT-2 在已见任务中表现如何，更重要的是，如何推广到新的对象、背景和环境？

2. 我们能否观察并测量 RT-2 的任何涌现能力？
3. 泛化如何随参数数量和其他设计决策而变化？
4. RT-2 是否能表现出类似视觉语言模型的思维链推理迹象？

我们评估了我们的方法以及包含约 6000 条评估轨迹的多个基线，涵盖多种条件下，具体内容将在后续章节中进行描述。除非另有说明，我们使用 7DoF 移动操作手，作用空间见第 3.2 节。我们还在项目网站 robotics-transformer2.github.io 展示了 RT-2 的实际操作示例。我们训练两个特定的 RT-2 实例，利用预训练的 VLMs： 1）RT-2-PaLI-X 基于 5B 和 55B PaLI-X 构建（Chen 等，2023a）， 2）RT-2-PaLM-E 基于 12B PaLM-E 构建（Driess 等，2023）。

在训练方面，我们利用了 Chen 等（2023a）和 Driess 等（2023）的原始网络量表数据，包括视觉问答、字幕以及非结构化的图像和文本交织示例。我们将此数据与 Brohan 等人（2022 年）在办公室厨房环境中收集的 13 台机器人演示数据结合起来。每个机器人演示轨迹都会用自然语言指令注释，描述所执行的任务，由一个描述技能的动词（例如“pick”、 “open”、 “place into”）和一个或多个描述作物体的名词组成（例如“7up 罐”、 “抽屉”、 “餐巾纸”） 详见附录 B，了解所用数据集的详细信息）。对于所有 RT-2 训练运行，我们采用了原始 PaLI-X（Chen 等，2023a）和 PaLM-E（Driess 等，2023）论文中的超参数，包括学习率计划和正则化。更多培训细节可见附录 E。

基线。我们将我们的方法与多个最先进的基线进行比较，这些基线对我们方法的不同方面提出了挑战。所有基线都使用完全相同的机器人数据。为了与最先进的政策进行比较，我们使用了 RT-1（Brohan 等，2022），这是一个基于 3500 万参数的变压器模型。为了与最先进的预训练表示进行比较，我们使用 VC-1（Majumdar 等，2023a）和 R3M（Nair 等，2022b），策略通过训练 RT-1 骨干将其表示为输入来实现。为了与其他使用 VLM 的架构进行比较，我们使用 MOO（Stone 等，2023），它利用 VLM 创建额外的语义图图像通道，然后输入 RT-1 骨干。更多信息见附录 C。

4.1. RT-2 在已见任务中表现如何，更重要的是，如何推广到新的对象、背景和环境？

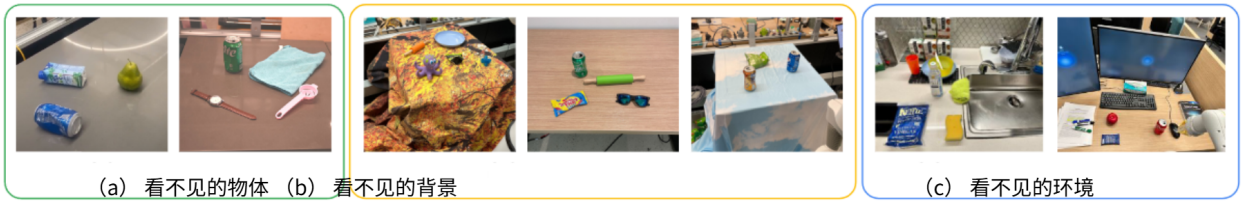

图 3 |图 4 和 6b 以及表 4 和表 6 中用于评估的范例推广情景。

为了评估分布内性能及泛化能力，我们将 RT-2-PaLI-X 和 RT-2-PaLM-E 模型与前述四条基线进行比较。对于已见任务类别，我们使用与 RT-1（Brohan 等，2022）相同的已见指令套件，该评估包含 200 多个任务：36 个用于拣选物品，35 个敲击物品，35 个放置物品，48 个用于移动物品，18 个用于开关各抽屉，36 个用于挑选和放入抽屉。但请注意，这些“分布内”评估仍会影响物体的位置及时间和机器人位置等因素，要求技能能够推广到环境中的真实变异性。

图 3 展示了推广评估的示例，这些评估被划分为未见的类别（对象、背景和环境），并进一步细分为简单和困难两种情况。对于看不见的物体，硬壳包括更难抓握和更独特的物体（如玩具）。对于看不见的背景，硬壳包含更多样化的背景和新奇物体。最后，对于看不见的环境，硬壳对应于带有显示器和配件的办公桌环境，而较简单的环境则是厨房水槽。这些评估包含 280 多个任务，主要聚焦于在多种场景中选择和放置技能。未见类别的说明列表载于附录 F.2。

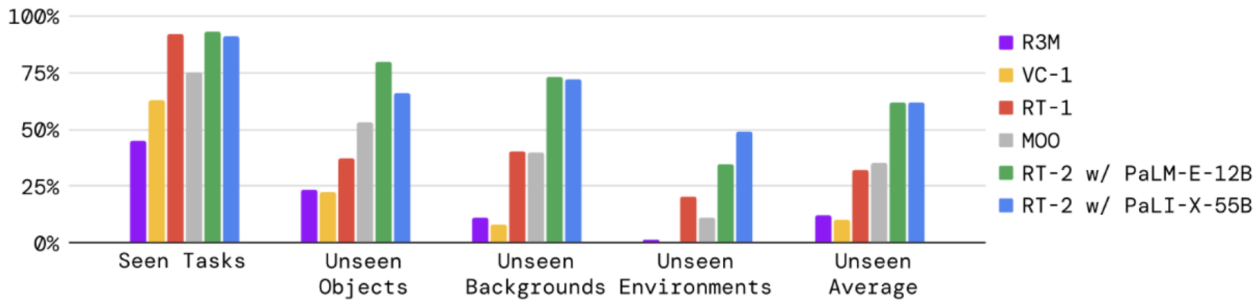

图 4 |两次 RT-2 实例化和基线在已见训练任务中的整体表现，以及测量对新对象、新背景和新环境的未见评估。

附录表 4 详细列出了完整结果。

评估结果如图 4 和附录表 4 所示。RT-2 型号与 RT-1 在实际任务上的表现相似，其他基线的成功率较低。RT-2 模型与基线模型的差异在各种泛化实验中最为明显，表明视觉-语言-动作模型的优势在于从其互联网规模的预训练数据中传递出更具推广性的视觉和语义概念。在这里，平均来看，RT-2 的两个实例表现相似，导致接下来的两个基线 RT-1 和 MOO 提升约 2 倍，且比其他基线提升约 6 倍。PaLM-E 版本的 RT-2 在较难的泛化场景中表现优于 RT-2-PaLI-X，但在简单场景中表现较差，导致平均性能相近。

开源语言表基准测试。为了利用开源基线和环境提供额外的比较点，我们利用了 Lynch 等人（2022）的开源 Language-Table 模拟环境。我们在多个预测任务（包括领域内 VQA 任务）上对较小的 PaLI 3B 模型进行协同微调，用于 Language-Table 数据集，并在模拟中评估所得策略。对于动作预测任务，我们将动作离散化并编码为格式为“X Y”的文本，其中 X 和 Y 的范围在{-10， -9， … . ， +9， +10}之间，代表末端执行器的δ二维笛卡尔集合点。由于体积较小，最终模型的推断速度与其他基线相似（5 Hz）。该实验结果见表 1。我们观察到使用本模型时性能显著提升，表明基于 VLM 的预训练结合大型 PaLI 模型的表现力，在其他场景中也有益处，即使用不同机器人的模拟。我们还在图 5 中展示了现实世界中分布外的定性行为，展示了该环境中前所未有的推送任务和目标目标。关于语言表实验的更多细节，可见附录 B 和 D。

4.2. 我们能否观察和测量 RT-2 的任何涌现能力？

除了评估视觉-语言-行动模型的泛化能力外，我们还旨在评估这些模型在多大程度上能够实现超越已展示的新能力

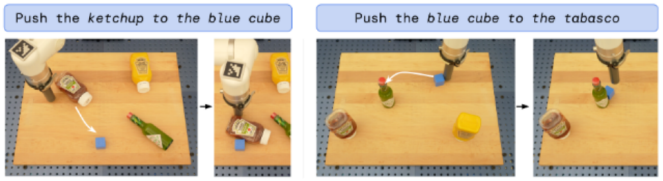

图 5 |语言表环境中的真实分布外行为。使用与标签 1 相同的 RT-2-PaLI-3B 型号检查点。

模型	语言表
BC-Zero（Jang 等，2021）72 ± 3	RT-1（Brohan 等，2022）74 ± 13
LAVA（Lynch 等，2022）77 ± 4	
RT-2-PaLI-3B（我们的）	90±10

表 1 |模拟语言表任务的表现（Lynch 和 Sermanet，2020）。

通过从网络传输知识，在机器人数据中进行。我们称这些能力为“涌现”，意指它们通过传输互联网规模的预训练而产生。我们不期望这种转移能够实现新的机器人运动，但我们预计语义和视觉概念，包括关系和名词，能够有效转移，即使这些概念在机器人数据中未被发现。

定性评估。首先，我们实验 RT-2-PaLI-X 模型，以确定从视觉语言概念转移的各种新兴能力。图 2 展示了一些此类相互作用的例子。通过我们的探索，我们发现 RT-2 在语义理解和场景背景下的基本推理方面继承了新颖的能力。例如，完成“把草莓放进正确碗里”这个任务，不仅需要对草莓和碗有细致理解，还需要在场景上下文中推理草莓应该搭配类似的水果。在“捡起即将从桌上掉落的包”任务中，RT-2 展示了物理理解，区分两个包并识别那个危险放置的物体。这些场景中测试的所有交互从未在机器人数据中出现，这表明语义知识是从视觉语言数据中转移而来的。

定量评估。为了量化这些涌现能力，我们取了之前评估中的前两条基线 RT-1 和 VC-1，并与我们的两款模型 RT-2-PaLI-X 和 RT-2-PaLM-E 进行比较。为了降低这些实验的方差，我们使用 A/B 测试框架（Fisher，1936）评估所有方法，其中四个模型在完全相同的条件下依次评估。

我们将 RT-2 的涌现能力分为三类，涵盖推理和语义理解两类（附录图 8 展示了各类示例）。第一种称为符号理解，明确测试 RT-2 策略是否传输了视觉语言预训练中未存在的语义知识。该类别的示例指令有“把苹果移到 3”或“把可乐罐推到心上”。第二类我们称之为推理，展示了将底层 VLM 推理的各个方面应用于控制任务的能力。这些任务需要视觉推理（“将苹果移到同色的杯子上”）、数学（“将 X 移动接近 2 加 1 的和”）和多语言理解（“mueve la manzana al vaso verde”）。我们称最后一类为人类识别任务，包括以下任务，我们还旨在评估此类模型在多大程度上能够实现超越“把可乐罐移给戴眼镜的人”的新能力，以展示以人为中心的理解和识别。用于此评估的完整指令列表详见附录 F.2。

我们将本次实验的结果展示在图 6a 中，所有数值结果则见附录 H.2。我们观察到，VLA 模型在所有类别中显著优于基线，最佳 RT-2-PaLI-X 模型的平均成功率超过下一最佳基线（RT-1）的 3 倍以上。我们还注意到，虽然基于 PaLI-X 的大型模型平均在符号理解、推理和人识别表现上表现更好，但基于 PaLM-E 的较小模型在涉及数学推理的任务中更具优势。我们将这一有趣结果归因于 PaLM-E 中使用的不同预训练混合，这使得模型在数学计算方面比主要以视觉预训练为主的 PaLI-X 更具能力。

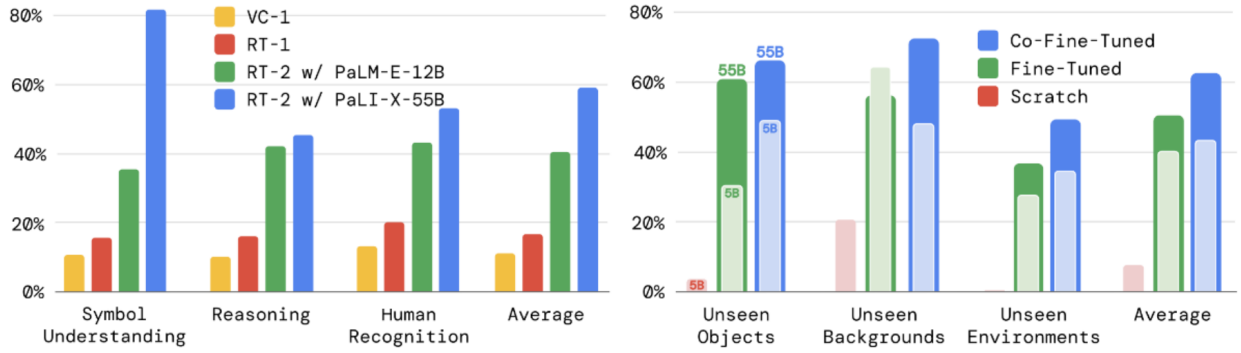

（a） RT-2 与两个基线在各种紧急技能评估中的表现比较（见图 8）。

（b）RT-2-PaLI-X 的消融，展示了参数计数和训练策略对泛化的影响。

图 6 |RT-2 在（6a）新兴技能和（6b）规模和训练消融中的定量表现。
附录表 5 和表 6 详细列出了完整的数值结果。

4.3. 泛化如何随参数数量和其他设计决策变化?

在本次比较中，我们使用 RT-2-PaLI-X 模型，因其在模型尺寸上的灵活性
（由于 PaLM-E 的特性，RT-2-PaLM-E 仅限于特定尺寸的 PaLM 和 ViT 型号。）特别地，我们比较了两种不同规模的模型，5B 和 55B，以及三种不同的训练流程：从零开始训练模型，不使用 VLM 预训练中的权重;仅使用机器人动作数据对预训练模型进行微调;以及协微调（与微调协同训练），这是本工作的主要方法，我们同时使用原始 VLM 训练数据和机器人数据进行 VLM 微调。由于我们主要关注这些模型的推广方面，因此从这组实验中剔除了所见任务的评估。

消融结果见图 6b 和附录表 6。首先，我们观察到从零开始训练一个非常大的模型，即使是 5B 模型，性能也非常差。基于此结果，我们决定跳过从零训练时对更大 55B PaLI-X 模型的评估。其次，我们注意到，无论模型大小，对模型进行协微调都能带来比单纯用机器人数据微调更好的泛化性能。我们认为，将原始数据保留在训练微调部分，使模型不会忘记在 VLM 训练中学到的先前概念。最后，稍显意外的是，模型规模的增大带来了更好的泛化性能。

4.4. RT-2 是否能表现出类似视觉-语言模型的思维链推理迹象?

受大型语言模型（LLMs）中的思维链提示法启发（Wei 等，2022），我们用 PaLM-E 微调 RT-2 的一个变体，仅经过几百个梯度步骤，以增强其结合语言和动作的能力，期望能引发更复杂的推理行为。我们补充数据，增加了一个额外的“计划”步骤，先用自然语言描述机器人即将执行的动作目的，然后是实际的动作标记，例如“指令：我饿了。计划：选 rxbar 巧克力。行动：1 128 124 136 121 158 111 255。”该数据增强方案作为 VQA 数据集（视觉推理）与操作数据集（生成动作）之间的桥梁。
我们定性观察到，RT-2 具有链式思维推理能力，能够响应更复杂的指令，因为它首先被赋予一个用自然语言规划行动的空间。这是一个有前景的方向，提供了初步证据，表明使用 LLM 或 VLM 作为规划工具（Ahn 等，2022;Driess 等，2023）可以与低层策略结合到单一的 VLA 模型中。带有思维链推理的 RT-2 推广见图 7 和附录 I。

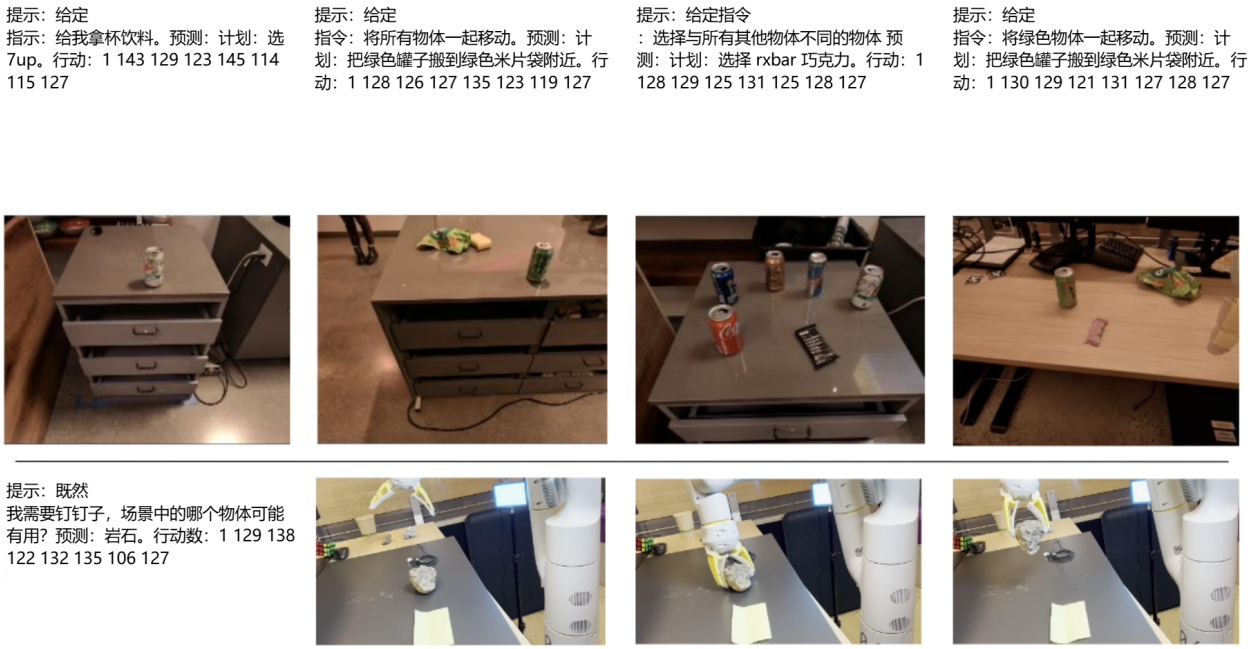

图 7 |RT-2 的推出，采用思维链推理，RT-2 既生成计划，也生成行动。

5. 限制

尽管 RT-2 展现出有前景的泛化特性，但该方法存在多重局限性。首先，虽然我们表明通过 VLM 进行网络规模预训练能提升语义和视觉概念的泛化，但机器人并未因包含这些额外经验而获得执行新动作的能力。模型的身体技能仍限于机器人数据中技能的分布（见附录 G），但它学会以新的方式部署这些技能。我们认为这是因为数据集在技能轴线上的多样性不足所致。未来一个令人兴奋的方向是研究如何通过新的数据收集范式（如人体视频）获得新技能。

其次，尽管我们证明可以实时运行大型 VLA 模型，但这些模型的计算成本很高，随着这些方法应用于需要高频控制的环境，实时推断可能成为一个主要瓶颈。未来研究的一个令人振奋的方向是探索量化和蒸馏技术，以实现此类模型在更高速率或更低成本硬件上的运行。这还与另一个电流限制有关，即可用来制作 RT-2 的 VLM 型号非常有限。我们希望未来会有更多开源模型（例如 https://llava-vl.github.io/），专有模型也能开放其微调 API，这已是构建 VLA 模型的充分需求。

6. 结论

本文描述了如何通过将视觉语言模型（VLM）预训练与机器人数据相结合来训练视觉语言动作（VLA）模型。随后，我们展示了基于 PaLM-E 和 PaLI-X 的两种 VLA 实例，分别称为 RT-2-PaLM-E 和 RT-2-PaLI-X。这些模型与机器人轨迹数据进行共微调，以输出机器人动作，这些动作以文本符号表示。我们证明了我们的方法能够产生非常高性能的机器人策略，更重要的是，带来了显著更好的泛化性能和继承的涌现能力

这带来了显著更好的泛化性能和继承自网络规模视觉语言预训练的涌现能力。我们认为，这种简单且通用的方法展现了机器人学直接受益于更优视觉语言模型的潜力，使机器人学习领域处于战略位置，能够随着其他领域的进步进一步提升。

致谢

我们要感谢弗雷德·阿尔科伯、乔迪·林恩·安德烈斯、卡罗莱纳·帕拉达、约瑟夫·达比斯、罗谢尔·德拉克鲁兹、杰西卡·戈麦斯、加文·冈萨雷斯、约翰·吉利亚德、托马斯·杰克逊、陈洁、斯科特·勒勒、迪·M、乌萨夫·马拉、阮莎拉、简·帕克、艾米莉·佩雷斯、埃利奥·普拉多、乔内尔·基安鲍、克莱顿·谭、乔德克斯蒂·瑟隆格、埃莉诺·汤姆林森、周文轩以及整个谷歌 DeepMind 团队的反馈和贡献。

参考文献

M. 安、A. 布罗汉、N. 布朗、Y. 切博塔尔、O. 科尔特斯、B. 大卫、C. 芬恩、K. 戈帕拉克里希南、K. 豪斯曼、A. 赫尔佐格等。尽我所能，而不是照我说的做：语言要扎根于机器人的赋能。arXiv 预印本 arXiv：2204.01691，2022。

J.-B. 阿莱拉克、J. 多纳休、P. 卢克、A. 米耶克、I. 巴尔、Y. 哈森、K. 伦奇、A. 门施、K. 米利肯、M. 雷诺兹等。Flamingo：一种用于少数样本学习的视觉语言模型。arXiv 预印本 arXiv：2204.14198,2022 年。

R. 阿尼尔、A. M. 戴、O. 菲拉特、M. 约翰逊、D. 莱皮欣、A. 帕索斯、S. 沙克里、E. 塔罗帕、P. 贝利、Z. 陈等。Palm 2 技术报告。arXiv 预印本 arXiv：2305.10403,2023 年。

A. Brohan、N. Brown、J. Carbajal、Y. Chebotar、J. Dabis、C. Finn、K. Gopalakrishnan、K. Hausman、A. Herzog、J. 许等。Rt-1：用于大规模实际世界控制的机器人变压器。arXiv 预印本 arXiv：2212.06817,2022 年。

T. 布朗、B. 曼、N. 赖德、M. 苏比亚、J. D. 卡普兰、P. 达里瓦尔、A. 尼拉坎坦、P. 沙姆、G. 萨斯特里、A. 阿斯克尔等。语言模型是少数样本学习者。神经信息处理系统进展，33：1877–1901,2020 年。

D. Cer、Y. Yang、S. Kong、N. Hua、N. Limtiaco、R. S. John、N. Constant、M. Guajardo-Cespedes、S. Yuan、C. Tar、Y. Sung、B. Strope 和 R. Kurzweil。通用句子编码器。CoRR，abs/1803.11175，

2018 年。网址 http://arxiv.org/abs/1803.11175。

陈明、特沃雷克、俊浩、袁琦、平托、卡普兰、爱德华兹、布尔达、约瑟夫、布罗克曼等。评估基于代码训练的大型语言模型。arXiv 预印本 arXiv：2107.03374,2021 年。

陈泽、乔隆加、帕德莱夫斯基、穆斯塔法、昌皮尼奥、吴、鲁伊斯、古德曼、王、泰、沙克里、德加尼、萨尔茨、卢奇奇、查嫩、纳格拉尼、胡、乔希、庞、蒙哥马利、皮耶特日克、里特、皮耶尔吉瓦尼、明德勒、帕维蒂奇、沃特斯、李、阿拉卜杜尔莫辛，L. 拜尔、J. 阿梅洛特、K. 李、A. P. 斯坦纳、李永、D. 凯瑟斯、A. 阿纳布、许耀，

K. 荣、A. 科列斯尼科夫、M. 谢耶多塞尼、A. 安杰洛娃、X. 扎伊、N. 霍尔斯比和 R. 索里库特。Pali-x：关于多语言视野与语言模型的扩展，2023a。

陈泽、王泽、昌平约、皮耶尔吉奥瓦尼、帕德莱夫斯基、萨尔茨、古德曼、格里茨纳、穆斯塔法、贝耶、科列斯尼科夫、普伊格塞尔维尔、丁、荣荣、阿克巴里、米什拉、薛、塔普利亚尔、布拉德伯里、郭、塞德多塞尼、贾、阿、阿彦、里克尔梅、斯坦纳、安杰洛娃、扎伊、霍尔斯比，以及 R. 索里卡特。Pali：一个联合尺度的多语言-图像模型，2023b。

K. 科布、V. 科萨拉朱、M. 巴伐利亚、M. 陈、H. Jun、L. 凯泽、M. 普拉佩特、J. 特沃雷克、J. 希尔顿、R. 中野等。训练验证器来解决数学应用题。arXiv 预印本 arXiv：2110.14168,2021 年。

蔡志志、王永、穆罕默德、平托等。从游戏到策略：从未经过筛选的机器人数据中生成条件行为。arXiv 预印本 arXiv：2210.10047,2022 年。

S. 达萨里和 A. 古普塔。变形金刚用于一次性视觉模仿。载于《机器人学习会议》，第 2071–2084 页。PMLR，2021 年。

S. 达萨里、F. 埃伯特、S. 田、S. 奈尔、B. 布歇尔、K. 施梅克佩珀、S. 辛格、S. 莱文和 C. 芬恩。

Robonet：大规模多机器人学习。载于 2019 年机器人学习会议。

M. 德加尼、J. 乔隆加、B. 穆斯塔法、P. 帕德莱夫斯基、J. 希克、J. 吉尔默、A. 斯坦纳、M. 卡隆、R. 盖尔霍斯、I. 阿拉卜杜尔莫辛、R. 杰纳顿、L. 贝耶、M. 查嫩、A. 阿尔纳布、X. 王、C. 里克尔梅、M. 明德雷尔、J. 普伊格塞尔弗、U. 埃夫奇、M. 库马尔、S. 范斯坦基斯特、G. F. 埃尔赛义德、A. 马亨德兰、F. 余、A. 奥利弗、F. 胡特、J. 巴斯廷斯， M. P. 科利尔、A. 格里岑科、V. 比罗德卡尔、C. 瓦斯孔塞洛斯、Y. 泰、T. 门辛克、A. 科列斯尼科夫、F. 帕韦蒂奇、D. 特兰、T. 基普夫、M. 卢契奇、X. 扎伊、D. 凯瑟斯、J. 哈姆森和 N. 霍尔斯比。

2023 年，将视觉变换器扩展到 220 亿参数。

D. Driess， F. Xia， M. S. Sajjadi， C. Lynch， A. Chowdhery， B. Ichter， A. Wahid， J. Tompson， Q. Vuong， T. Yu 等。Palm-e：一种具身多模态语言模型。arXiv 预印本 arXiv：2303.03378,2023 年。

M. 杜、S. 奈尔、D. 萨迪格和 C. 芬恩。行为检索：通过查询无标签数据集进行的少数样本模仿学习。arXiv 预印本 arXiv：2304.08742,2023a。

Y. 杜、K. 科纽什科娃、M. 德尼尔、A. 拉朱、J. 兰登、F. 希尔、N. 德弗雷塔斯和 S. 卡比。视觉语言模型作为成功探测器。arXiv 预印本 arXiv：2303.07280,2023b。

C. 芬恩和 S. 莱文。深层视觉预见，用于机器人运动规划。2017 年 IEEE 国际机器人与自动化会议（ICRA），第 2786–2793 页。IEEE，2017 年。

C. 芬恩、T. 余、张陶、P. 阿比尔和 S. 莱文。通过元学习实现一次性视觉模仿学习。
载于《机器人学习会议》，第 357–368 页。PMLR，2017 年。

R. A. 费舍尔。实验设计。 英国医学杂志》，1（3923）：554,1936 年。

S. Y. 加德雷、M. 沃茨曼、G. 伊尔哈科、L. 施密特和 S. 宋。夹式轮子：零射点目标导航，作为物体定位和探索。arXiv 预印本 arXiv：2203.10421,2022 年。

Z. Gan、L. Li、C. Li、L. Wang、Z. Liu、J. Gao 等。视觉语言预训练：基础知识，最新进展，
以及未来趋势。 《计算机图形学与视觉的基础与趋势®》，14（3–4）：163–352,2022 年。

G. Ghiasi、X. Gu、Y. Cui 和 T.-Y.Lin. 开放词汇图像分割。arXiv 预印本 arXiv：2112.12143,2021 年。

K. 格劳曼、A. 韦斯特伯里、E. 拜恩、Z. 查维斯、A. 弗纳里、R. 吉尔达尔、J. 汉堡、H. 江、M. 刘、M. 刘、M. 马丁、T. 纳加拉詹、I. 拉多萨沃维奇、S. K. 拉马克里希南、F. 瑞安、J. 夏尔马、M. 雷、M. 徐、E. Z. 徐、C. 赵、S. 班萨尔、D. 巴特拉、V. 卡蒂利耶、S. 克兰、T. Do、M. 杜拉蒂、A. 埃拉帕利， C. 费希滕霍弗、A. 弗拉戈梅尼、Q. 傅、A. 格布雷塞拉谢、C. 冈萨雷斯、J. 希利斯、黄晓、黄永、贾文、库、科拉尔、科拉尔、科图尔、库马尔、兰迪尼、李、李、李、李、李、曼加拉姆、莫杜古、门罗、穆罗、穆雷尔、西安、普赖斯、普伦特斯、拉马扎诺瓦、萨里、索马松达拉姆、萨瑟兰， 萨瑟兰， 菅野、陶光、沃、王、吴晓、八木、赵志、朱、阿贝拉埃兹、克兰德尔、达门、法里内拉、富根、加内姆、伊萨普、贾瓦哈尔、朱、北谷、李、纽科姆、奥利瓦、朴、雷、佐藤、石、邹、邹、邵， A. 托拉尔巴、L. 托雷萨尼、M. 颜和 J. 马利克。Ego4d：环游全球 3000 小时的自我中心视频，2022 年。

X・九，T.-Y。林伟、郭伟、崔永。通过视觉和语言知识提炼实现开放词汇对象检测。arXiv 预印本 arXiv：2104.13921， 2021。

N. 汉森、R. 江吉尔、Y. 孙、G. 阿伦尼亚、P. 阿贝尔、A. A. 埃弗罗斯、L. 平托和 X. 王。部署期间的自我监督政策调整。arXiv 预印本 arXiv：2007.04309， 2020。

郝耀、宋荣、董立、黄志、池志、王宇、马、魏富。语言模型是通用接口。arXiv 预印本 arXiv：2206.06336， 2022。

F. 希尔、S. 莫克拉、N. 黄和 T. 哈雷。人类指令跟随与通过文本迁移学习实现深度强化学习。arXiv 预印本 arXiv：2005.09382， 2020。

黄志、董永、王伟、郝义、辛格哈尔、马、吕志、崔志、O. K. 穆罕默德、刘志志等。语言不是全部：将感知与语言模型对齐。arXiv 预印本 arXiv：2302.14045,2023 年。

黄文、阿比尔、帕塔克和莫达奇。语言模型作为零样本规划器：为具身代理提取可操作知识。载于国际机器学习会议，第 9118–9147 页。PMLR，2022 年。

S. 詹姆斯、M. 布洛施和 A. J. 戴维森。任务嵌入式控制网络用于少数样本模仿学习。载于《机器人学习会议》，第 783–795 页。PMLR，2018 年。

E. 张、A. 伊尔潘、M. 汗萨里、D. 卡普勒、F. 埃伯特、C. 林奇、S. 莱文和 C. 芬恩。Bc-z：零射任务推广与机器人模仿学习。载于《机器人学习会议》，第 991–1002 页。PMLR，2021 年。

姜义、古普塔、张志、王、窦义、陈义、菲菲、阿南德库马尔、朱义、范。

Vima：通用机器人操作，带有多模态提示。arXiv 预印本 arXiv：2210.03094,2022 年。

L. P. 凯尔布林。高效机器人学习的基础。 科学》，369（6506）：915–916,2020 年。

S. 卡拉姆切蒂、S. 奈尔、陈 A. S. 、T. 科拉尔、C. 芬恩、D. 萨迪格和梁 P.机器人领域的语言驱动表征学习。arXiv 预印本 arXiv：2302.12766,2023 年。

A. 基里洛夫、E. 明顿、N. 拉维、H. 毛、C. 罗兰、L. 古斯塔夫森、T. 肖、S. 怀特黑德、A. C. 伯格、W.-Y.Lo 等人。分段任何内容。arXiv 预印本 arXiv：2304.02643， 2023。

I. 科斯特里科夫、D. 亚拉茨和 R. 弗格斯。图像增强就是你所需要的全部：规范从像素进行深度强化学习。arXiv 预印本 arXiv：2004.13649， 2020。

M. 拉斯金、K. 李、A. 斯图克、L. 平托、P. 阿比尔和 A. 斯里尼瓦斯。增强数据的强化学习。神经信息处理系统进展，33 卷：19884–19895,2020a。

M. 拉斯金、A. 斯里尼瓦斯和 P. 阿贝尔。卷曲：用于强化学习的对比无监督表征。载于《国际机器学习会议》，第 5639–5650 页。PMLR，2020b。

S. 莱文、P. 帕斯托尔、A. 克里热夫斯基、J. 伊巴尔兹和 D. 奎伦。学习手眼协调，用于深度学习和大规模数据收集的机器人抓取。 国际机器人研究杂志》，37（4-5）：421–436,2018 年。

A. Lewkowycz、A. Andreassen、D. Dohan、E. Dyer、H. Michalewski、V. Ramasesh、A. Slone、C. Anil、I. Schlag、T. Gutman-Solo 等。用语言模型解决定量推理问题。

arXiv 预印本 arXiv：2206.14858,2022 年。

李志、李大、萨瓦雷塞和海志。Blip-2：利用冻结图像编码器和大型语言模型进行语言-图像预训练的引导。arXiv 预印本 arXiv：2301.12597,2023 年。

李李、亚茨卡尔、尹大、C.-J.谢氏和 K.-W.昌。Visualbert：一个简单且高效的视觉与语言基线。arXiv 预印本 arXiv：1908.03557,2019 年。

刘荣、李荣、李启和阿比尔。与联合预训练视觉语言模型的指令跟随智能体。arXiv 预印本 arXiv：2210.13431,2022 年。

J. 卢、D. 巴特拉、D. 帕里克和 S. 李。Vilbert：预训练视觉与语言任务相关的无关性视觉语言学表示。神经信息处理系统的进展，32,2019 年。
C. 林奇和 P. 塞尔马内。语言条件模仿学习，基于非结构化数据。arXiv 预印本 arXiv：2005.07648， 2020。
C. 林奇、A. 瓦希德、J. 汤普森、T. 丁、J. 贝特克、R. 巴鲁克、T. 阿姆斯特朗和 P. 弗洛伦斯。互动语言：与机器人实时对话。arXiv 预印本 arXiv：2210.06407,2022 年。
Y. J. 马、S. 索达尼、D. 贾亚拉曼、O. 巴斯塔尼、V. 库马尔和张 A.VIP：走向普世视觉

通过价值隐性预训练实现奖励和代表。arXiv 预印本 arXiv：2210.00030,2022 年。

Y. J. 马、W. 梁、V. Som、V. Kumar、A. 张、O. 巴斯塔尼和 D. 贾亚拉曼。Liv：语言-图像表征与机器人控制奖励。arXiv 预印本 arXiv：2306.00958， 2023。

J. 马勒、J. 梁、S. 尼亚兹、M. 拉斯基、R. 端、X. 刘、J. A. 奥杰亚和 K. 戈德堡。Dex-net 2.0：深度学习，利用合成点云和分析抓取指标规划稳健抓取。arXiv 预印本 arXiv：1703.09312,2017 年。
A. 马朱姆达尔、K. 亚达夫、S. 阿尔诺、Y. J. 马、C. 陈、S. 西尔瓦尔、A. 贾因、副会长伯格斯，P. 阿贝尔，J. 马利克等。我们在寻找具身智能人工视觉皮层的过程中处于什么阶段？arXiv 预印本 arXiv：2303.18240,2023a。
A. 马朱姆达尔、K. 亚达夫、S. 阿尔诺、Y. J. 马、C. 陈、S. 西尔瓦尔、A. 贾因、副会长伯格斯，P. 阿贝尔，J. 马利克等。我们在寻找具身智能人工视觉皮层的过程中处于什么阶段？arXiv 预印本 arXiv：2303.18240,2023b。
O. 米斯、L. 赫尔曼和 W. 伯加德。在语言条件化机器人模仿学习中，什么才是关键的，尤其是在非结构化数据之上。《IEEE 机器人与自动化快报》，7（4）：11205–11212,2022 年。
M. 明德勒、A. 格里岑科、A. 斯通、M. 诺伊曼、D. 魏森博恩、A. 多索维茨基、A. 马亨德兰、A. 阿尔纳布、M. 德加尼、Z. 沈等。简单的开放词汇对象检测，配合视觉变换器。arXiv 预印本 arXiv：2205.06230， 2022。
穆义、张启、胡文、王伟、丁文、金志、王伯、戴志、乔耀、罗鹏。具身 GPT：通过具身思维链进行视觉语言预训练。arXiv 预印本 arXiv：2305.15021， 2023。
S. 奈尔、E. 米切尔、陈凯、萨瓦雷塞、C. 芬恩等。通过离线数据和众包注释学习语言条件机器人行为。载于《机器人学习会议》，第 1303–1315 页。

PMLR，2022a。

S. 奈尔、A. 拉杰斯瓦兰、V. 库马尔、C. 芬恩和 A. 古普塔。R3m：一种通用的机器人操作视觉表示。arXiv 预印本 arXiv：2203.12601,2022b。

OpenAI。GPT-4 技术报告，2023 年。

J. 帕里、N. M. 沙菲乌拉、S. P. 阿鲁纳查拉姆和 L. 平托。表征学习在视觉模仿方面的惊人效果。arXiv 预印本 arXiv：2112.01511,2021 年。
L. 平托和 A. 古普塔。超大自我监督：从 5 万次尝试和 700 次机器人中学习掌握

几个小时。2016 年 IEEE 国际机器人与自动化会议（ICRA），第 3406–3413 页。
IEEE，2016 年。

S. 波卢、J. M. 韩、郑启、M. 巴克西斯、I. 巴布什金和 I. 苏茨凯弗。形式数学陈述课程学习。arXiv 预印本 arXiv：2202.01344， 2022。

V. H. 庞、M. 达拉尔、S. 林、A. 奈尔、S. 巴尔和 S. 莱文。偏置拟合：覆盖状态的自我监督强化学习。arXiv 预印本 arXiv：1903.03698,2019 年。

A. 拉德福德、J. W. 金、C. 哈拉西、A. 拉梅什、G. 戈、S. 阿加瓦尔、G. 萨斯特里、A. 阿斯克尔、P. 米什金、J. 克拉克等。从自然语言监督中学习可迁移的视觉模型。载于国际机器学习会议，第 8748–8763 页。PMLR，2021 年。

S. 里德、K. 佐尔纳、E. 帕里索托、S. G. 科尔梅纳雷霍、A. 诺维科夫、G. 巴特-马龙、M. 吉门尼斯、Y. 苏尔斯基、J. 凯、J. T. 斯普林根伯格等。一个通才经纪人。arXiv 预印本 arXiv：2205.06175,2022 年。

M. 梁、A. 皮耶吉奥瓦尼、A. 阿尔纳布、M. 德加尼和 A. 安杰洛娃。Tokenlearner：自适应时空视频的代币化。 神经信息处理系统进展》，34：12786–12797,2021 年。

D. 沙阿、B. 奥辛斯基、b. 伊希特和 S. 莱文。Lm-nav：具有大型预训练语言、视觉和动作模型的机器人导航。载于刘启、库利奇和伊奇诺夫斯基主编， 第六会议录》机器人学习会议， 机器学习研究论文集》第 205 卷，第 492 页至今504。PMLR，2023 年 12 月 14–18 日。网址 https://proceedings.mlr.press/v205/shah23b.html。

R. 沙阿和 V. 库马尔。RRL：Resnet 作为强化学习的表示。arXiv 预印本 arXiv：2107.03380,2021 年。

M. 施里达尔、L. 马努埃利和 D. 福克斯。Cliport：机器人操作的路径和路径。载于第五届机器人学习会议论文集（CoRL），2021 年。

M. 施里达尔、L. 马努埃利和 D. 福克斯。Cliport：机器人操作的路径和路径。载于《机器人学习会议》，第 894–906 页。PMLR，2022a。

M. 施里达尔、L. 马努埃利和 D. 福克斯。感知者-行为者：用于机器人操作的多任务变换器。arXiv 预印本 arXiv：2209.05451,2022b。

I. 辛格、V. 布鲁基斯、A. 穆萨维安、A. 戈亚尔、D. 徐、J. 特朗布莱、D. 福克斯、J. 托马森和 A. 加尔格。Progprompt：利用大型语言模型生成情境机器人任务计划。ICRA，2023 年。

M. H. 史密斯和 L. S. 科尔斯。设计一款低成本、通用机器人。载于 IJCAI，第 324–336 页，1973.

A. 斯通，T. Xiao，Y. Lu，K. 戈帕拉克里希南，K.-H.李、Q. 冯、P. 沃尔哈特、B. 齐特科维奇、F. 夏、C. 芬恩等。使用预训练视觉语言模型进行开放世界对象操作。arXiv 预印本 arXiv：2303.00905， 2023。

T. 苏默斯、K. 马里诺、A. 阿胡贾、R. 弗格斯和 I. 达斯古普塔。将互联网规模的视觉语言模型提炼为具身的代理。arXiv 预印本 arXiv：2301.12507,2023 年。

郑义雄、德甘尼、陈振、加西亚、魏志、王振、钟、沙克里、巴里、舒斯特、郑、周、霍尔斯比和梅茨勒。UL2：统一语言学习范式，2023 年。

S. 文普拉拉、R. 博纳蒂、A. 巴克尔和 A. 卡普尔。ChatGPT 机器人：设计原则与模型能力。Microsoft Auton。系统机器人。Res，2023 年 2：20。

王志志、杨志、胡晓、李志、林光、甘志、刘志、刘志和王立。Git：一款用于视觉和语言的生成图像转文本转换器。arXiv 预印本 arXiv：2205.14100,2022 年。

J. Wei、X. Wang、D. Schuurmans、M. Bosma、E. Chi、Q. Le 和 D. Zhou。思维链提示在大型语言模型中激发推理。arXiv 预印本 arXiv：2201.11903,2022 年。

J. Wei、L. Hou、A. Lampinen、X. Chen、D. Huang、Y. Tay、X. Chen、Y. Lu、D. Zhou、T. 马，以及 Q. V. Le。符号调谐提升了语言模型中的上下文学习能力，2023 年。

吴志贤、安东诺娃、坎文、莱珀特、曾志、宋志、博格、鲁辛基维奇和冯克豪泽。Tidybot：针对大型语言模型的个性化机器人辅助。arXiv 预印本 arXiv：2305.05658，2023 年。

T. Xiao、H. Chan、P. Sermanet、A. Wahid、A. Brohan、K. Hausman、S. Levine 和 J. Tompson。通过视觉语言模型进行指令增强的机器人技能习得。arXiv 预印本 arXiv：2211.11736,2022a。

T. 萧、I. 拉多萨沃维奇、T. 达雷尔和 J. 马利克。带面具的视觉预训练用于运动控制。arXiv 预印本 arXiv：2203.06173,2022b。

S. 杨、D. 甘地、S. 图尔西亚尼、A. 古普塔、P. 阿贝尔和 L. 平托。视觉模仿变得简单。载于《机器人学习会议》，第 1992–2005 页。PMLR，2021 年。

K.-T. 余、M. 鲍扎、N. 法泽利和 A. 罗德里格斯。推销方式超过一百万种。高保真

平面推入的实验数据集。2016 年 IEEE/RSJ 国际智能机器人与系统会议（IROS），第 30–37 页。IEEE，2016 年。

T. 余、C. 芬恩、谢安、S. 达萨里、张陶、P. 阿贝尔和 S. 莱文。通过领域自适应元学习观察人类的一次性模仿。arXiv 预印本 arXiv：1802.01557,2018 年。

X. 扎伊、A. 科列斯尼科夫、N. 霍尔斯比和 L. 贝耶。视野变换器扩展。载于 IEEE/CVF 计算机视觉与模式识别会议论文集，第 12104–12113 页，2022 年。

张晓明、丁永、阿米里、杨明、卡明斯基、埃塞林克和张。通过视觉语言模型为经典任务规划器奠定基础。arXiv 预印本 arXiv：2304.08587,2023 年。

答：贡献

- 训练与评估（设计和执行训练模型的程序，在仿真和现实世界中评估模型，运行算法设计的消融

  选择：叶夫根・切博塔尔、克日什托夫・乔罗曼斯基、丁天利、丹尼・德里斯、阿维纳瓦・杜贝伊、皮特・弗洛伦斯、傅楚媛、蒙特塞・冈萨雷斯・阿雷纳斯、基尔塔娜・戈帕拉克里希南、韩克恒、亚历山大・赫尔佐格、布莱恩・伊希特、亚历克斯・伊尔潘、伊莎贝尔・利尔、丽莎・李、姚璐、亨利克・米哈莱夫斯基、伊戈尔・莫尔达奇、卡尔・佩奇、迈克尔・梁、阿尼凯特・辛格、权武、艾赞・瓦希德、保罗・沃尔哈特、菲・夏、特德・萧和天和于。
- 网络架构（设计和实现模型网络模块，致力于动作的分词化，实现实验中模型网络的推断）：叶夫根・切博塔尔、习 陈、克日什托夫・乔罗曼斯基、丹尼・德里斯、皮特・弗洛伦斯、基尔塔娜・戈帕拉克里希南、韩凯恒、卡罗尔・豪斯曼、布莱恩・伊希特、亚历克斯・伊尔潘、伊莎贝尔・利尔、丽莎・李、亨利克・米哈莱夫斯基、伊戈尔・莫尔达奇、卡尼什卡・拉奥、迈克尔・梁、阿尼凯特・辛格、权武， 艾赞・瓦希德、吴嘉林、菲夏、晓泰德和于天和。

- 数据收集（收集真实机器人数据，进行真实机器人评估，执行运行真实机器人所需的操作）：Noah Brown、Justice Carbajal、Tianli Ding、Krista Reymann、Grecia Salazar、Pierre Sermanet、Jaspiar Singh、Huong Tran、Stefan Welker 和 Sichun Xu。

- 领导层（领导项目工作，管理项目团队，提供项目方向建议）：叶夫根・切博塔尔、切尔西・芬恩、卡罗尔・豪斯曼、布赖恩・伊希特、谢尔盖・莱文、姚璐、伊戈尔・莫尔达奇、卡尼什卡・拉奥、潘纳格・桑凯蒂、拉杜・索里库特、文森特・范霍克和天和余。

- 纸张（在纸质手稿上工作，设计纸质可视化和图形）：
  叶夫根・切博塔尔、丹尼・德里斯、切尔西・芬恩、皮特・弗洛伦斯、卡罗尔・豪斯曼、布莱恩・伊希特、丽莎・李、谢尔盖・莱文、伊戈尔・莫尔达奇、卡尔・佩奇、权翁、飞霞、萧泰德和于天和。
- 基础设施（负责训练模型、运行实验、存储和访问数据所需的基础设施和代码库骨干）：Anthony Brohan、Yevgen Chebotar、Danny Driess、Kehang Han、Jasmine Hsu、Brian Ichter、Alex Irpan、Nikhil Joshi、Ryan Julian、Dmitry Kalashnikov、Yuheng Kuang、Isabel Leal、Lisa Lee、曾伟 Edward Lee、Yao Lu、Igor Mordatch、Quan Vuong、Ayzaan Wahid、Fei Xia， 肖泰德、彭旭和余天和。

B. 数据集

视觉语言数据集基于 Chen 等人（2023b）和 Driess 等人（2023）的数据集混合。这些数据的大部分来自 WebLI 数据集，约有 10B 对图像-文本，跨 109 种语言，筛选出评分最高的 10%跨模态相似性示例，以获得 1B 训练示例。还包括许多其他字幕和视觉问题解答数据集，关于数据集混合物的更多信息可见 Chen 等人（2023b）关于 RT-2-PaLI-X 的研究和 Driess 等人（2023 年）关于 RT-2-PaLM-E 的研究。在对 RT-2-PaLI-X 进行共微调时，我们不使用 Chen 等（2023a）描述的 Episodic WebLI 数据集。

机器人数据集基于 Brohan 等人（2022）的数据集。该项目包括用移动操作机器人收集的演示节目。每个演示都附有七个技能中的自然语言指令： 选取物品”、 将物体移近物体”、 将物体竖直”、 推倒物体”、 打开抽屉”、 关闭抽屉”、 将物品放入容器”和“从容器中取物并放在柜台上”。更多细节可见 Brohan 等（2022）。

RT-2-PaLI-X 对机器人数据集进行了权重，使其约占训练混合数据的 50%

用于共微调。RT-2-PaLM-E 对机器人数据集的权重约占训练混合的 66%。

对于表 1 中 Language-Table 的结果，我们的模型是在 Lynch 等人（2022）的 Language-Table 数据集上训练的。我们的模型在多个预测任务上进行了协同微调： 1）在两个连续的图像帧和一条文本指令下预测动作;（2）在给定图像帧的情况下预测指令;（3）在给定图像帧的情况下预测机器人手臂的位置;（4）预测给定图像帧之间的时间步长数;以及（5）根据图像帧和指令预测任务是否成功。

C. 基线

我们将我们的方法与多个最先进的基线进行比较，这些基线对我们方法的不同方面提出了挑战。所有基线都使用完全相同的机器人数据。

- RT-1：机器人变压器 1 Brohan 等（2022）是一个基于变压器的模型，在发布时在类似任务套件上实现了最先进的性能。该模型不使用基于 VLM 的预训练，因此提供了重要的数据点，证明基于 VLM 的预训练是否重要。

- VC-1：VC-1 Majumdar 等人（2023a）是一个视觉基础模型，使用专门为机器人任务设计的预训练视觉表示。我们使用 VC-1 ViT-L 模型的预训练表示。由于 VC-1 不包含语言条件反射，我们通过通用句子编码器 Cer 等人（2018）单独嵌入语言命令，以便与我们的方法进行比较。特别地，我们将所得的语言嵌入令牌与 VC-1 生成的图像令牌串接，并将串接后的令牌序列传递给令符学习器 Ryoo 等人（2021）。令牌学习器产生的令牌序列随后被仅支持 RT-1 解码器的变换器模型取用，以预测机器人动作令牌。我们会端到端训练 VC-1 基线，并在训练时解冻 VC-1 负重，因为这样比使用冷冻的 VC-1 配重效果要好得多。

- R3M：R3M Nair 等人（2022b）与 VC-1 类似，R3M 使用预训练的视觉语言表示来改进政策培训。在此案例中，作者使用了 Ego4D 数据集（Grauman 等人，2022）关于人类活动的资料来学习策略所使用的表征。VC-1 和 R3M 都测试了不同的最先进表示学习方法，作为 VLM 的替代方案。为了从 R3M 预训练表示中获得语言条件策略，我们遵循上述 VC-1 的相同程序，但使用 R3M ResNet50 模型获取图像标记，并在训练时解冻。

- MOO：MOO Stone 等人（2023）是一种以对象为中心的方法，首先使用 VLM 指定目标对象，以原始图像中单个彩色像素的形式出现。像素修改后的图像随后通过端到端策略进行训练，以完成一系列操作任务。该基线对应于 VLM 作为增强感知的独立模块，但其表示方式不用于政策学习的情况。

D. RT-2 的 VLM

PaLI-X 模型架构由 ViT-22B Dehghani 等人（2023）组成，用于处理图像，该图像可接受 n 张图像的序列，导致每张图像有 n ×k 个符号，k 是每张图像的补丁数。经过投影层的图像标记随后被一个由 32B 参数和 50 层组成的编码-解码器骨干所消耗，类似于 UL2 Tay 等（2023），该系统将文本和图像作为嵌入共同处理，以自回归方式生成输出标记。文本

文本输入通常包括任务类型及任何附加上下文（例如，字幕任务的“生成⟨语言⟩”，VQA 任务的“用⟨⟩语言回答：问题”）。

在 Language-Table 上训练的 PaLI-3B 模型（表 1）使用较小的 ViT-G/14（Zhai 等，2022） 2B 参数）处理图像，UL2-3B（Tay 等，2023）用于编码-解码器网络。
PaLM-E 模型基于仅解码器的大型语言模型，该模型将机器人数据（如图像和文本）投射到语言令牌空间，并输出文本如高级计划。在所用的 PaLM-E-12B 中，用于将图像投射到语言嵌入空间的视觉模型是 ViT-4B，Chen 等人（2023b）。连续变量与文本输入的连接使 PaLM-E 实现完全多模态，接受多种输入，如多传感器模态、以对象为中心的表示、场景表示和对象实体的引用。

E. 培训详情

我们对来自 PaLI-X（Chen 等，2023a）5B 和 55B 模型、PaLI（Chen 等，2023b）3B 模型以及 PaLM-E（Driess 等，2023）12B 模型的预训练模型进行了协微调。对于 RT-2-PaLI-X-55B，我们使用学习率 1e-3 和批次大小 2048，并对模型进行 80K 梯度同步微调;而对于 RT-2-PaLI-X-5B，我们使用相同的学习率和批次大小，并对 270K 梯度同步微调模型。对于 RT-2-PaLM-E-12B，我们使用学习率 4e-4 和批次大小 512 来对模型进行 1M 梯度同步微调。这两个模型都以下一个令牌预测目标训练，对应于机器人学习中的行为克隆损失。对于表 1 中用于语言表结果的 RT-2-PaLI-3B 模型，我们使用学习率 1e-3 和批处理大小 128，以共同微调 30 万梯度步长。

F. 评估详情

F.1. 评估场景

为了定量研究 RT-2 的涌现能力，我们研究了各种具有挑战性的语义评估场景，旨在衡量推理能力、符号理解和人类识别等能力。图 8 提供了部分场景的视觉概述，完整用于定量评估的指令列表见表 3。

F.2. 评估说明

表 2 列出了用于模型评估中对未可见对象、背景和环境的自然语言指令。每条指令运行 1 到 5 次，具体取决于该评估集的总指令数。表 3 列出了用于评估定量涌现评估的自然语言指令。每条指令运行 5 次。

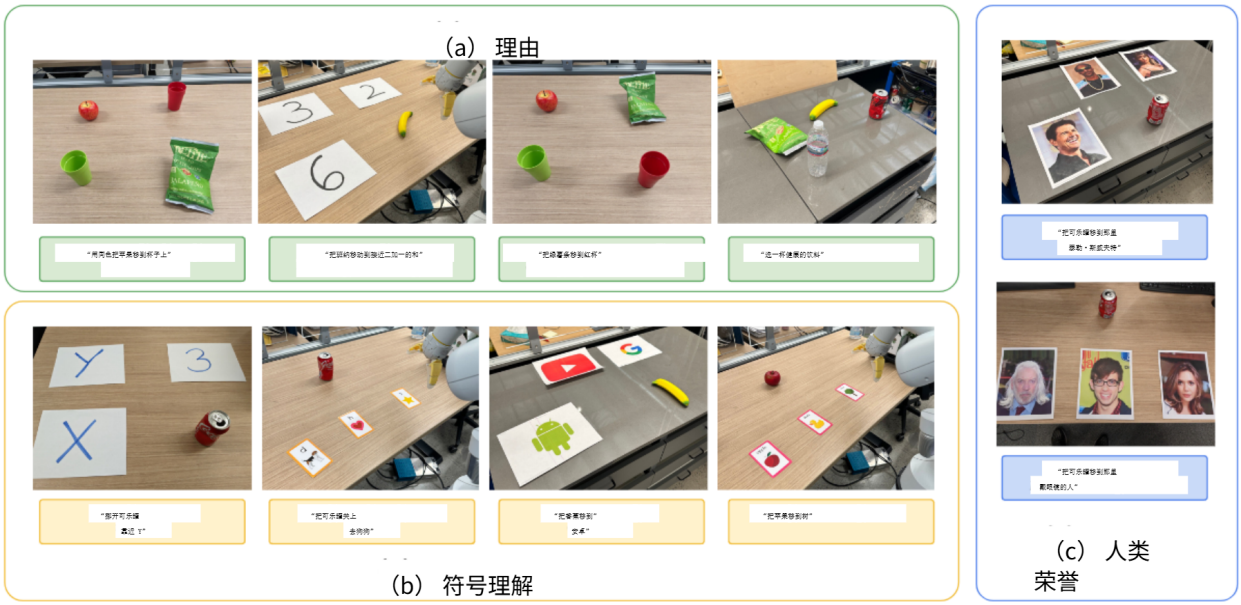

图 8 |研究 RT-2 新兴能力时所采用的一些评估场景概述。它们聚焦于三大类： (a) 推理， (b) 符号理解，以及 (c) 人类识别。可视化指令是完整指令的子集，完整指令列于附录 F.2。

工作组	任务
符号理解——ing：符号 1	把可乐罐移到 X 附近，把可乐罐移到 3 附近，把可乐罐移到 Y 附近
符号理解——译者：符号 2	将苹果移到树上，将苹果移到鸭子，将苹果移到苹果，再将苹果移到相匹配的牌上
符号理解——ing：符号 3	把可乐罐放近狗狗，把可乐罐放在心口，把可乐罐放在星星上方
推理：数学	将香蕉移到 2，将香蕉移近 2 加 1 的和，将香蕉移近 3 乘以 2 的答案，将香蕉移近最小的数
理由：标志	把杯子移到谷歌，把杯子移到安卓，把杯子移到 YouTube，把杯子移到搜索引擎，把杯子移到手机
理由：营养	给我拿点健康零食，选一杯健康饮料，拿点甜饮料，把健康零食换到健康饮料，拿点咸味零食
理由：肤色与多语言	将苹果移到同色杯子，将不同颜色的苹果移到杯子，将绿色薯片移到同色杯子，将苹果移到绿叶，在机械的 Tasse 中完成，将绿色薯片移至红叶，将绿色薯片移到绿色的葡萄糖上，将绿色薯条移到红色的糖果上
人员识别：名人	把可乐罐卖给泰勒·斯威夫特，把可乐罐卖给汤姆·克鲁斯，把可乐罐卖给史努比狗
人员识别：名人	把可乐罐移到戴眼镜的人那里，把可乐罐移给白发男人，把可乐罐搬给棕发女士

表 3 |用于定量涌现评估的自然语言指令。

G. 失败案例示例

图 9 中我们举例说明了语言表设置中一种显著的失败案例，即 RT-2 模型未能推广到未见对象动态。在这些情况下，尽管模型能够正确关注语言指令并移动到第一个正确对象，但它无法控制这些对象的复杂动态，这些动态与在该环境中观察到的少量块对象有显著差异（Lynch 等人，2022）。然后笔会直接从桌面滚落（见图 9，左），而香蕉的质心远离机器人接触点（见图 9，右）。我们注意到，推力动态以难以预测和控制而闻名，Yu 等人（2016）。我们假设通过进一步扩展数据集在不同环境和对象上的扩展——例如，本例中包含类似类型、更多样化推力动态的数据集，可能实现机器人-环境交互动态的更大泛化（Dasari 等人（2019）。

此外，尽管 RT-2 在现实操作任务中的定性和定量新发评估表现令人期待，但仍存在许多显著的失败案例。例如，在当前的训练数据集组成和训练方法下，RT-2 在以下方面表现不佳：

- 通过特定部件抓取物体，比如把手
- 机器人数据中看到的全新动作，如用毛巾擦拭或使用工具
- 灵巧或精准的动作，比如叠毛巾
- 扩展推理需要多层间接推理

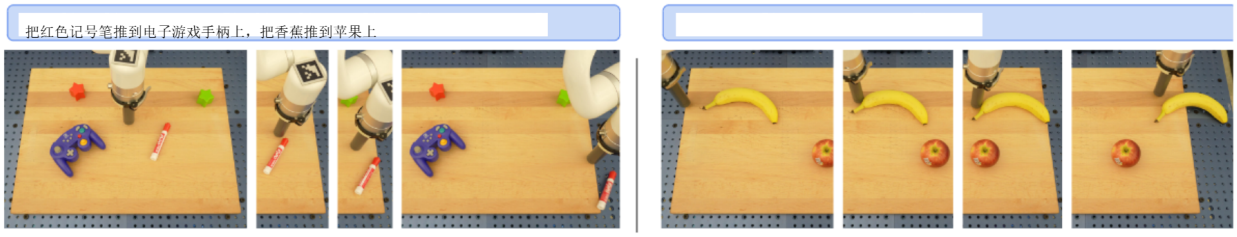

图 9 |现实世界中无法推广到看不见物体动力学的定性失败案例。

H. 定量实验结果

H.1. 整体表现，适用于第 4.1 节

表 4 列出了我们的定量总体评估结果。我们发现 RT-2 在可见任务上的表现与基线相当甚至更好，且在对未见物体、背景和环境的泛化方面显著优于基线。

模型	已见任务	看不见的物体		未见背景		未见环境		未见的平均值
		慢点	非常困难	慢点	非常困难	慢点	非常困难	
R3M（Nair 等，2022b）	45	32	14	13	9	0	2	12
VC-1（Majumdar 等，2023a）	63	34	10	13	3	0	0	10
RT-1（Brohan 等，2022）	92	31	43	71	9	26	14	32
MOO（Stone 等，2023）	75	58	48	38	41	19	3	35
RT-2-PaLI-X-55B（我们的）	91	70	62	96	48	63	35	62
RT-2-PaLM-E-12B（我们的）	93	84	76	75	71	36	33	62

表 4 |两次 RT-2 实例化和基线在已见训练任务中的整体表现，以及测量对新对象、新背景和新环境的未见评估。

H.2. 紧急评估，针对第 4.2 节

表 5 列出了我们所有的定量涌现评估结果。我们发现 RT-2 在这些新指令下表现是 RT-1 的 2 到 3 倍，且无需额外机器人演示。这展示了我们的方法如何利用网络规模视觉语言数据集的预训练能力。

模型	符号理解			推理			个人识别平均值	
	符号 1	符号 2	符号 3	平均数学	标志	营养	颜色/多语言	平均名人 名人平均
VC-1（Majumdar 等，2023a）	7	25	0	11	0	8	20	13
10 20 7 13 11 RT-1（Brohan 等，2022）	27	20	0	16	5	0	32	28
16 20 20 20 17 RT-2-PaLI-X-55B（我们的）	93	60	93	82	25	52	48	58
46 53 53 53 60 RT-2-PaLM-E-12B（我们的）	67	20	20	36	35	56	44	35
43 53 43 40								

表 5 |RT-2 及定量新兴评估基线的表现。

H.3. 尺寸与训练消融，适用于第 4.3 节

表 6 详细列出了跨模型规模和训练方法的消融定量结果。在每个模型中，我们都看到模型规模在性能中起着重要作用，而共微调优于微调，而精细调优于从零开始训练。

模型	规模	培训	看不见的物体		未见背景		未见环境		平均值
			慢点	非常困难	慢点	非常困难	慢点	非常困难	
RT-2-PaLI-X	5B	从零开始	0	10	46	0	0	0	9
RT-2-PaLI-X	5B	微调	24	38	79	50	36	23	42
RT-2-PaLI-X	5B	共微调	60	38	67	29	44	24	44
RT-2-PaLI-X	55B	微调	60	62	75	38	57	19	52
RT-2-PaLI-X	55B	共微调	70	62	96	48	63	35	63

表 6 |RT-2 的消融展示了参数计数和训练策略对泛化的影响。

一、额外的思维链推理结果

我们展示了更多使用 RT-2-PaLME 实现的思维链推理展开示例，详见图 4.4 节，见图 10。

[1] PaLM-E-12B 中使用的原始预训练数据组合（如 Driess 等（2023）所述）包含用于高级 VQA 规划任务的机器人图像，这些图像可类似于泛化场景中遇到的图像。然而，这些训练示例中没有包含本实验中评估的低层次动作。

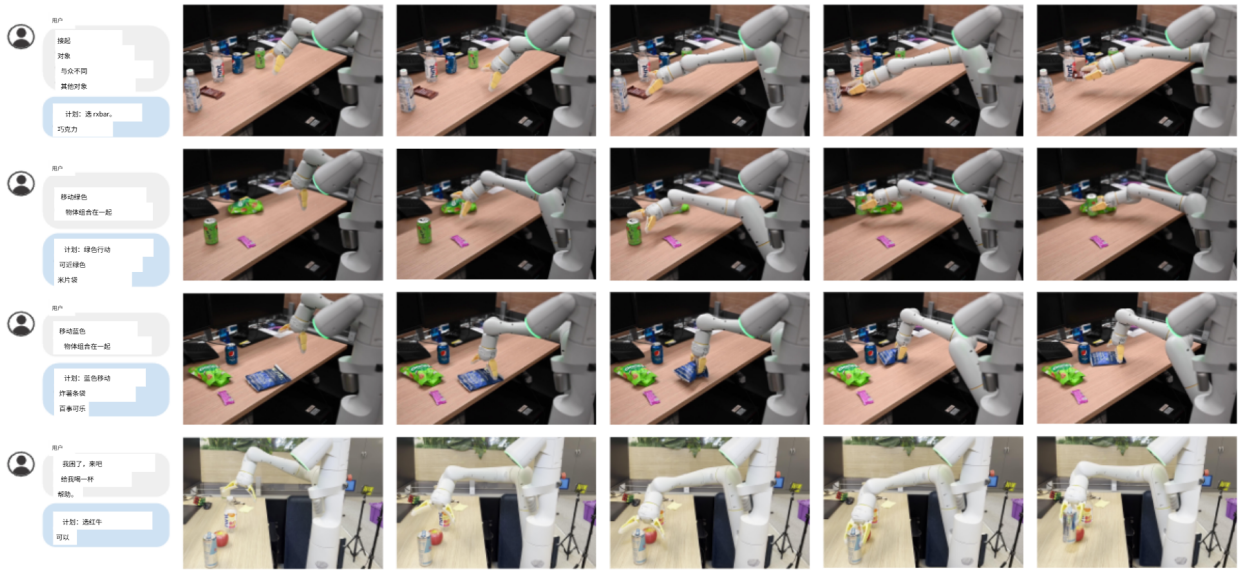

图 10 |带有思维链推理的 RT-2 其他示例

工作组	任务
看不见的物体（简单）	摘香蕉，把香蕉搬到可乐罐附近，把橙罐搬到香蕉旁边，挑奥利奥，把奥利奥搬到苹果附近，把红牛罐搬到奥利奥附近，挑梨，挑椰子水，把梨搬到椰子水附近，把百事可乐罐靠近梨
看不见的物体（困难）	挑冷萃罐，挑大橙盘，挑咬咬玩具，挑大号网球，挑鸟饰品，挑鱼玩具，挑姜柠檬康普茶，挑蛋壳隔板，挑手表，挑绿色雪碧罐，挑蓝色超细纤维布，挑黄色梨，挑椒盐脆片袋，挑消毒湿巾，挑菠萝提示水，挑绿色杯子， 挑泡菜零食，挑小蓝盘子，挑小橙色擀面杖，挑章鱼玩具，挑猫薄荷玩具
未曾露面的背影——场地（简单）	选绿色墨西哥薯片袋，挑橙罐，挑百事可乐罐，挑 7up 罐头，挑苹果，挑蓝薯袋，挑橙子，挑 7up 罐，把橙子搬到水槽附近，挑可乐罐，挑海绵，挑 Rxbar 蓝莓。
未曾露面的背影——地面（困难）	选手表，选蛋壳隔板，选绿色雪碧罐，选蓝色超细纤维布，选黄色梨，选椒盐卷饼薯片袋，选消毒湿巾，选菠萝提示水，选绿色杯子，选泡菜零食，选小蓝盘子，挑小橙色擀面杖，选章鱼玩具，选猫薄荷玩具，选瑞典鱼袋，选大号绿色擀面杖， 选黑色太阳镜
看不见的环境——ments（简单）	挑可乐罐，挑苹果，摘 Rxbar 蓝莓，把苹果搬到可乐罐附近，搬 Rxbar 蓝莓靠近苹果，搬到 RXBAR 蓝莓附近，挑蓝色塑料瓶，挑海绵，挑蓝筹袋，搬到蓝色塑料瓶附近的海绵，搬到海绵附近的蓝色塑料袋，搬到蓝芯片袋附近，搬到白色杯子附近，搬到白色杯子附近。 把白杯附近的海绵移开，黄色碗附近的可乐罐，黄色碗附近的海绵，绿色布附近的可乐罐，绿色布附近的海绵，盘子附近的可乐罐，盘子附近的海绵，勺子附近的可乐罐，勺子附近，橙色杯子附近的可乐罐，橙色杯子附近的海绵，橙色杯子附近的海绵， 挑白杯，挑黄碗，挑绿布，把白杯移到海绵旁，把黄色碗移到海绵旁，把绿布移到海绵旁，挑盘子，挑勺子，挑橙色杯子，把盘子移到海绵旁边，把勺子移到海绵旁边，把橙色杯子移到海绵旁边，把可乐罐放进水槽，把可乐罐扔进水槽，推可乐罐进水槽，把海绵放进水槽，把海绵扔进水槽，把海绵推进水槽，把绿色布放进水槽，把绿色布放进水槽，把绿色布推进水槽
看不见的环境——门托（困难）	拣可乐罐，挑苹果，摘 Rxbar 蓝莓，把苹果搬近可乐罐，搬 Rxbar 蓝莓靠近苹果，搬 Rxbar 蓝莓附近的可乐罐，搬近 Rxbar 蓝莓，搬近订书机的可乐罐，搬近订书机的苹果，把键盘附近的可乐罐移，靠近纸巾盒的可乐罐，搬近纸巾箱的苹果，搬近纸张的可乐罐， 把苹果靠近纸张，把可乐罐移到鼠标附近，把苹果移到鼠标附近，把可乐罐移到书旁边，把苹果移到书旁边，拿记号笔，拿订书机，挑鼠标，把记号机移到苹果附近，把订书机移到苹果附近，把鼠标移到苹果附近，把可乐罐推到左边，把可乐罐推到右边，把海绵推到左边， 向右推海绵，向左推纸巾盒，向右推纸巾盒，指向可乐罐，指向海绵，指向纸巾盒

表 2 |用于评估测试的自然语言指令控制了新对象、新环境和新背景维度上的分布变化。对于每个类别，我们引入了分布偏移较小和较大分布转移的评估设置。图 3 展示了这些情景的可视化。